

SISTEM VIDEO PENTRU DETECȚIA URMĂRITORILOR DIN TRAFIC

Candidat: Nastasia-Elena, Nițu

Coordonator științific: Asist. SL dr.ing. ec. Valentin-Adrian, Niță

Sesiunea: Iunie 2022

REZUMAT

Acestă lucrare de diplomă este realizată în cadrul departamentului de Electronică Aplicată al Universității Politehnica din Timișoara.

Recunoașterea Automată a Numerelor de Înmatriculare integrează tehnici de Computer Vision (și nu numai) în cadrul domeniului Sistemelor Inteligente de Transport, domeniu din ce în ce mai important în ultimii ani.

Domeniul Recunoașterii Automate a Numerelor de Înmatriculare din trafic nu este dezvoltat în totalitate pentru România față de dezvoltările existente în alte țări. Creșterea cercetărilor în cadrul acestui domeniu reprezintă un factor pozitiv pentru securitatea în trafic și nu numai. Dezvoltarea unor instrumente specializate pentru România prezintă o importanță maximă, dacă nu chiar o necesitate.

Sistemul propus în cadrul acestui proiect preia ca input flux de date în timp real de folosind o cameră web conectată unui sistem Raspberry Pi, procesează fluxul de date folosind tehnologii de actualitate și returnează atenționări instantanee cu privire la posibile autoturisme ce pot urmări utilizatorul în trafic în scopuri diverse.

Lucrarea folosește conceptele de procesare de imagine și învățare automată pentru a duce la final sarcinile impuse.

Testarea sistemului în timp real dovedește că metoda propusă oferă rezultatele așteptate, cu o acuratețe ridicată. Rezultatele deschid o cale către dezvoltări ulterioare, ce pot fi componente importante în cadrul domeniilor Automotive, Sisteme Inteligente de Transport și Securitate Personală.

Cuvinte cheie: Python, Raspberry Pi, OCR, Procesare de imagine, Învățare prin transfer, Tensorflow

ABSTRACT

This diploma thesis is carried out within the department of Applied Electronics of the Polytechnic University of Timișoara.

Automatic License Plate Recognition integrates Computer Vision techniques (and more) into the field of Intelligent Transportation Systems, a field that has become increasingly important in recent years.

The field of Automated License Plate Recognition is not fully developed for Romania compared to existing developments in other countries. Increasing research in this area is a positive factor for traffic safety and beyond. The development of specialized tools for Romania is of utmost importance, if not a necessity.

The system proposed in this project takes as input real-time data flow using a webcam connected to a Raspberry Pi system, processes the data flow using current technologies and returns instant alerts on possible cars that could be following the user in traffic in various purposes.

The paper uses the concepts of Image Processing and Machine Learning to complete the required tasks.

Real-time system testing proves that the proposed method delivers the expected results with high accuracy. The results pave the way for further developments, which could be important components in the fields of Automotive, Intelligent Transportation Systems and Personal Security.

Keywords: Python, Raspberry Pi, OCR, Image Processing, Transfer Learning, Tensorflow

Mulțumiri

Rămân profund recunoscătoare domnului Valentin-Adrian Niță, pentru timpul, expertiza, răbdarea, sfaturile și inspirația oferite pe tot parcursul realizării acestui proiect. Fără sprijinul acestuia, acest proiect nu ar fi putut exista.

Domnului Dan Lascu îi mulțumesc pentru că a fost mai mult decât un decan, ascultând cu adevărat doleanțele fiecărui student, dovedindu-și empatia și compasiunea în fiecare zi.

Nu îi pot uita nici pe fratele meu Cătălin, pe părinții mei, pe bunicii mei, pe Alexandru, pe doamna profesoară Ana Borcean, pe domnul profesor Mircea-Petru Rusu și pe psih. Doru Constantin Bălan, care mi-au oferit sprijinul și m-au îndrumat mereu către calea ce îmi era potrivită. Nu aș fi ajuns aici fără voi.

Anexa 1

Autorul lucrării:
Nițu Nastasia Elena

Titlul lucrării:
Sistem video pentru detecția automată a urmăritorilor din trafic

Structură lucrare:

1. Introducere
2. Metode de detecție obiecte
3. Optimizare detecție în funcție de iluminare și viteză de deplasare
4. Proiectare sistem hardware
5. Algoritmi detecție urmăritori
6. Comunicare cu utilizatorul
7. Concluzii

Lucrarea trebuie finalizată ca:

- Studiu theoretic
- Simulare
- Implementare de metodă/algoritm într-un limbaj de programare

Data completării:

Luni, 8 noiembrie 2021, 15:46

Profesorul coordonator:

NIȚĂ VALENTIN-ADRIAN

Coordonatorul din partea companiei:

Compania în cadrul căreia a fost realizată licența:

Anexa 2

Autorul lucrării:
Nițu Nastasia Elena

Scopul proiectului:

Prezenta lucrare (Sistem video pentru detecția automată a urmăritorilor din trafic) propune realizarea unui sistem de recunoaștere automată a numerelor de înmatriculare, folosind Python, Raspberry Pi, Deep Learning și OCR.

Detecția realizată se face pe baza unor fișiere imagine sau în timp real, cu flux de date live de la o resursă de tip cameră web.

Scopul utilizării acestui sistem este atenționarea în timp real a utilizatorului cu privire la posibile autovehicule ce îl urmăresc în scopuri rele.

Cuvinte cheie:

Deep Learning, Transfer Learning, OCR, Python, Image Processing, Tensorflow, Raspberry Pi

Cuprinsul proiectului:

1. Introducere
2. Metode de detecție obiecte
3. Optimizare detecție în funcție de iluminare și viteză de deplasare
4. Proiectare sistem hardware
5. Algoritmi detecție urmăritori
6. Comunicare cu utilizatorul
7. Concluzii

Referințe bibliografice:

1. [Studies in Fuziness and Soft Computing 352] Arindam Chaudhuri, Krupa Mandaviya, Pratixa Badelia, Soumya K Ghosh (auth.) – Optical Character Recognition Systems for Different Languages with Soft Computing (2017, Springer International Publishing AG)
2. Shervin Minaee, Yuri Boykov, Fatih Porikli, Antonio Plaza, Nasser Kehtarnavaz and Demetri Terzopoulos – Image Segmentation Using Deep Learning_A Survey (2020, arXiv)
3. <https://medium.com/@quangnhatnguyenle/detect-and-recognize-vehicles-license-plate-with-machine-learning-and-python-part-1-detection-795fda47e922>, accesat la data de 07.05.2022
4. <https://towardsdatascience.com/how-to-detect-license-plates-with-python-and-yolo-8842aa6d25f7>, accesat la data de 07.05.2022

5. <https://medium.com/@thephilebuyssens/license-plate-recognition-using-opencv-yolo-and-keras-f5bfe03afc65>, accesat la data de 07.05.2022

Activități desfășurate – până în 07.05.2022 (prezentare succintă, numerotată):

1. Studiu teoretic – studiul referințelor bibliografice, studiul a diferite lucrări științifice și articole deja existente din domeniul Inteligenței Artificiale, Automotive și Machine Learning
2. Studiu pentru implementare – studiul a diferite medii de programare, metode și tool-uri ce pot fi folosite; alegerea celor potrivite proiectului
3. Investigare coduri sursă deja existente
4. Realizarea unui algoritm de bază, ce face detecția numerelor de înmatriculare pe baza unor fișiere imagine, dar și în timp real, de la o resursă de tip cameră web

Listă figuri

Figură 1 – Exemplu de sistem ANPR [5]	13
Figură 2 – Topul țărilor europene cu privire la victimele traficului de persoane [22]	14
Figură 3 – Numărul de mașini furate în România în perioada 2016-2021 [25]	16
Figură 4 – Analiza SWOT a sistemului	21
Figură 5 – Exemplu de segmentare a caracterelor [5]	26
Figură 6 – Procesul de Învățare automată.....	27
Figură 7 – Procesul de învățare automată (detalii).....	28
Figură 8 – Procesul de Recunoaștere Automată a Caracterelor	31
Figură 9 – Subprocese pentru realizarea unui model de Recunoaștere optică a caracterelor [40]	32
Figură 10 – Conexiunea laterală și calea de sus în jos, îmbinate prin însumare [45]	36
Figură 11 - Un exemplu de detectare a unui indicator de oprire într-o imagine. Caseta de delimitare prezisă este desenată cu roșu, în timp ce caseta de delimitare a adevărului de bază este desenată în verde [48]......	39
Figură 12 – Suprafața de suprapunere [48]	40
Figură 13 – Suprafața de uniune [48]......	40
Figură 14 - Precizia medie, recall-ul mediu și pierderile în funcție de IoU, la pasul 10000.....	42
Figură 15 – Rata de învățare, Pierderea de clasificare, Pierderea de localizare, Pierderea de regularizare și Pierderea totală, în funcție de pasul de antrenare	42
Figură 16 - Rata de învățare în funcție de pasul de antrenare	43
Figură 17 - Pierderea de clasificare în funcție de pasul de antrenare	43
Figură 18 - Pierderea de localizare în funcție de pasul de antrenare	44
Figură 19 – Pierderea de regularizare în funcție de pasul de antrenare	44
Figură 20 – Pierderea totală în funcție de pasul de antrenare	45

Listă tabele

Tabel 1 – Rata criminalității în România, pe județe [25]	15
Tabel 2 – Precizia medie în funcție de IoU	41
Tabel 3 – Recall-ul mediu în funcție de IoU	41
Tabel 4 – Precizia medie, recall-ul mediu și pierderile în funcție de IoU, la pasul 10000	41

Cuprins

1.	INTRODUCERE.....	11
1.1	CONTEXT	13
1.2	OBSTACOLE	18
1.3	OBIECTIVE	19
1.4	STRUCTURA LUCRĂRII	20
2.1	DESCRIEREA CATEGORIILOR DE UTILIZATORI	22
2.2	CERINȚE DE SISTEM (HARDWARE ȘI SOFTWARE)	22
2.3	CERINȚE FUNCȚIONALE/NEFUNCȚIONALE	23
2.4	MODELĂRI ALE SISTEMULUI	23
3.1	PRODUSE COMERCIALE	25
3.2	METODE EXISTENTE	26
4.1	Tehnologii utilizate	27
6.1	TESTARE	45
6.2	EVALUARE	45
7.1	UTILITATE	46
7.2	DEZVOLTĂRI ULTERIOARE	46
8	Referințe bibliografice	48

1. INTRODUCERE

Recunoașterea automată a plăcuțelor de înmatriculare (eng. Automatic Number Plate Recognition – ANPR) este tehnologia ce utilizează recunoașterea optică a caracterelor (eng. Optical Character Recognition – OCR) pe fișiere de tip imagine pentru a citi caracterele alfanumerice de pe plăcuțele de înmatriculare a vehiculelor, cu scopul, de obicei, de a capta date despre vehicul și locația acestuia [a].

Alte denumiri folosite frecvent:

- Automatic (or automated) license-plate recognition (ALPR),
- Automatic (or automated) license-plate reader (ALPR),
- Automatic vehicle identification (AVI),
- Automatisk nummerpladegenkendelse (ANPG),
- Car-plate recognition (CPR),
- License-plate recognition (LPR),
- Lecture automatique de plaques d'immatriculation (LAPI),
- Mobile license-plate reader (MLPR),
- Vehicle license-plate recognition (VLPR),
- Vehicle recognition identification (VRI) [a],

În continuare, vom folosi majoritar termenul de ANPR, cu anumite abateri în citări.

ANPR poate folosi televiziunea cu circuit închis (eng. Closed-Circuit Television – CCTV), camere de supraveghere cu scopul de a monitoriza respectarea regulilor rutiere sau camere special concepute pentru această sarcină [a].

Această tehnologie este folosită majoritar de forțele de poliție din întreaga lume în scopuri de aplicare a legii (respectarea limitelor de viteză legale sau determinarea cazului în care un vehicul este înmatriculat sau autorizat). De asemenea, tehnologia este folosită pentru colectarea electronică a taxelor pe drumurile ce necesită plata unei taxe pentru utilizare, dar și ca metodă de catalogare a fluxului de trafic, de exemplu de către agențiile publice de autostrăzi.

Recunoașterea automată a plăcuțelor de înmatriculare poate fi folosită pentru a stoca imaginile surprinse de camere, precum și textul de pe plăcuța de înmatriculare, dar și alte aspecte (unele sisteme sunt configurate pentru a stoca și o fotografie a șoferului).

Sistemele folosesc în mod obișnuit tehnologia cu infraroșu pentru a permite camerei să facă poze la orice oră din zi sau din noapte [1] [2].

ANPR a fost inventat în 1976 la sediul Police Scientific Development Branch din Marea Britanie. Sistemele prototip funcționau deja în 1979 și au fost realizate contracte

pentru producerea de sisteme industriale, mai întâi în colaborare cu EMI Electronics, iar apoi Computer Recognition Systems (CRS, acum parte a companiei Jenoptik) din Wokingham, Marea Britanie. Sistemele prototip timpurii au fost implementate pe drumul A1 din Regatul Unit și în tunelul Dartford din aceeași națiune. Prima arestare prin detectarea unei mașini furate a fost făcută în 1981. Tehnologia ANPR, însă, nu a devenit utilizată pe scară largă decât abia în anii 1990, când au fost lansate noi dezvoltări în software mai ieftine și mai ușor de utilizat [3].

Colectarea datelor ANPR pentru utilizare ulterioară (adică pentru soluționarea infracțiunilor neidentificate la momentul realizării acestora) a fost documentată la începutul anilor 2000. Primul caz documentat în care ANPR a fost folosit pentru a ajuta la rezolvarea unei crime a avut loc în noiembrie 2005, în Bradford, Marea Britanie, la condamnarea ucigașilor lui Sharon Beshenivsky, agent de Poliție britanic [4].

Aspectul software al sistemului rulează pe hardware-ul standard al unui computer și poate fi conectat la alte aplicații sau baze de date. Mai întâi se utilizează o serie de tehnici de procesare de imagine pentru a detecta, normaliza și îmbunătăți imaginea plăcuței de înmatriculare, iar apoi se realizează recunoașterea optică a caracterelor pentru a extrage cifrele alfanumerice ale plăcuței de înmatriculare.

Sistemele ANPR sunt, în general, implementate într-una dintre cele două abordări de bază: una permite ca întregul proces să fie efectuat la locația preluării de imagine în timp real, iar celălalt transmite toate imaginile la un computer aflat la distanță și realizează, ulterior, procesarea.

Când recunoașterea automată a numărului de înmatriculare se realizează la locul de bază, informațiile capturate ale plăcii alfanumerice, data, ora și orice alte informații necesare sunt procesate complet în aproximativ 250 de milisecunde [5]. În celălalt aranjament, există de obicei un număr mare de PC-uri interconectate pentru a gestiona sarcini mari de lucru. Adesea, în astfel de sisteme, există o cerință de a transmite imagini către serverul aflat la distanță, iar acest lucru poate necesita medii de transmisie cu lățime de bandă mare.

Utilizări:

- Aplicarea legilor rutiere (identificarea vehiculelor neînmatriculate, furate și neasigurate, precum și a șoferilor descalificați sau suspendați, precum și a altor persoane de interes, cum ar fi persoanele cu mandate de arestare emise pe numele acestora) [6],
- Colectarea taxelor de drum sau a taxelor de parcare,
- Monitorizarea traficului [7],



Figură 1 – Exemplu de sistem ANPR [5]

- Monitorizarea respectării vitezei legale în trafic [8],
- Colectarea de date ce pot fi folosite ulterior în cazuri penale,
- Servicii de securitate pentru întreprinderi [9] (exemplu: înregistrarea numerelor de înmatriculare a mașinilor ce părăsesc stațiile de alimentare fără a plăti),
- Instrumente de marketing personalizat și publicitate direcționată [10],
- Recunoașterea automată a vizitatorilor pe domenii private,
- Testarea automată a emisiilor din trafic [11],
- Calculul duratei necesare unei călătorii,
- Etc.

1.1 CONTEXT

Nevoia și importanța acestui proiect rezultă în urma statisticilor de siguranță civilă realizate pe teritoriul României.

În primul rând, aproape 6000 de copii au dispărut de acasă în anul 2021 [12]. Dintre aceștia, 19% sunt răpiți în contextul proceselor de stabilire a custodiei parentale, iar, în 20% din cazuri, apelurile din presă și sistemele de alertă pentru copii au jucat un rol important în găsirea copiilor dispăruți [13]. Alerte pot fi lansate și pe baza numărului de înmatriculare în cazul răpirii cu ajutorul unui vehicul, autoritățile putând lansa mesaje de atenționare folosind chiar platforma ROALERT. Vehiculul în cauză ar putea fi detectat de sisteme de detecție automată a plăcuței de înmatriculare.


De asemenea, în România, aproape zilnic sunt difuzate știri noi cu privire la diferite evenimente de violență fizică în trafic [14] [15] [16]. De foarte multe ori, șoferi agresivi urmăresc victima până ce ajung într-un punct în care atacul poate fi realizat cu ușurință. Un sistem de detecție a potențialilor urmăritori avertizează viitoarea victimă, iar aceasta, la rândul ei, poate lua măsurile necesare de siguranță.

Adițional, tot mai des sunt prinși la volan șoferi fără permis sau cu permisul de conducere suspendat sau chiar anulat [17] [18]. Acești șoferi ar putea fi detectați în trafic de către forțele de ordine, folosind baze de date privind posesorii unor astfel de autovehicule.

O altă statistică arată că violența domestică este un fenomen ce ia amploare în România. În ultimii 8 ani (luând ca reper anul 2021), 426 de femei au fost ucise în România

În urma violenței domestice (de partenerii lor, de foștii parteneri sau de membri ai familiei), potrivit datelor oferite de Centrul Filia, ONG care luptă pentru drepturile femeilor și pentru combaterea violenței domestice [19]. În aceeași perioadă de timp, peste 1000 de apeluri au fost preluate de operatorii din centrele împotriva violenței domestice [20]. Un alt procent îngrijorător este că, potrivit Poliției Române, aproximativ 40% din ordinele de protecție emise pentru astfel de cazuri sunt încălcate [21]. Persoanele ce sunt victime ale violenței domestice ar putea beneficia de o siguranță sporită folosind sisteme de detecție automată a urmăritorilor din trafic. Un sistem care atenționează cu privire la autovehicule ce au fost marcate în trecut ca fiind periculoase ar fi ideal pentru această categorie socială. În plus, baza de date ce are centralizate vehiculele al căror număr de înmatriculare a fost detectat, data detecțiilor și recurența acestora ar putea constitui o dovadă importantă pentru cererea unui ordin de restricție.

Un alt raport îngrijorător provine de la Statista, din 2016, unde România ocupă locul al treilea în rândul țărilor europene cu cel mai mare număr de persoane traficate [22], cu 757 de victime raportate. Acest număr devine alarmant în comparație cu populația României (757 de victime la o populație de 19 de milioane de locuitori), raportându-ne, de exemplu, la Marea Britanie (1358 de victime la o populație de 67 de milioane de locuitori). Și aici, ca și în cazul copiilor răpiți, sistemele de detecție a numerelor de înmatriculare pot juca un rol principal în combaterea acestui tip de infracțiune.




Figură 2 – Topul țărilor europene cu privire la victimele traficului de persoane [22]

Neliniștitor este și faptul că, din cele 41 de județe ale României plus zona București, în 15 dintre acestea rata criminalității este ridicată, adică în aproape o treime, conform Asociației Naționale a Evaluatoarelor de Risc la Securitatea Fizică din România [23]. Detecție urmăritorilor în timp real poate oferi o siguranță în viața cotidiană a fiecărui cetățean român ce se deplasează cu un autovehicul.

Coeficienții de criminalitate specifică la nivel de județe pentru anul 2020			
Nr. crt.	Județul	Coeficient de criminalitate județean (%)	Domeniu de încadrare a ratei de criminalitate
TOTAL	Media criminalității naționale 2020	502.95	
1	AB	56.67	SCAZUT
2	AR	72.17	SCAZUT
3	AG	79.93	MEDIU
4	BC	130.43	RIDICAT
5	BH	87.28	MEDIU
6	BN	40.16	SCAZUT
7	BT	49.71	SCAZUT
8	BV	143.35	RIDICAT
9	BR	74.56	SCAZUT
10	BZ	57.86	SCAZUT
11	CS	56.47	SCAZUT
12	CL	23.26	SCAZUT
13	CJ	149.32	RIDICAT
14	CT	155.88	RIDICAT
15	CV	21.47	SCAZUT
16	DB	41.36	SCAZUT
17	DJ	104.58	RIDICAT
18	GL	105.97	RIDICAT
19	GR	43.54	SCAZUT
20	GJ	28.43	SCAZUT
21	HR	22.47	SCAZUT
22	HD	99.21	MEDIU
23	IL	45.53	SCAZUT
24	IS	199.82	RIDICAT
25	IF	147.93	RIDICAT
26	MM	65.61	SCAZUT
27	MH	16.70	SCAZUT
28	MS	113.33	RIDICAT
29	NT	74.16	SCAZUT
30	OT	59.85	SCAZUT
31	PH	165.42	RIDICAT
32	SM	34.99	SCAZUT
33	SJ	28.03	SCAZUT
34	SB	106.37	RIDICAT
35	SV	78.54	MEDIU
36	TR	39.96	SCAZUT
37	TM	139.97	RIDICAT
38	TL	25.05	SCAZUT
39	VS	74.76	SCAZUT
40	VL	58.65	SCAZUT
41	VN	48.91	SCAZUT
42	DGPMB	1032.30	RIDICAT

Tabel 1 – Rata criminalității în România, pe județe [23]

Pe site-ul oficial al Poliției Române sunt aproximativ 22000 de mașini listate ca fiind furate [24]. Dintre acestea, 1448 au fost marcate ca fiind furate în anul 2021 [25]. Adicional, în același an, au fost identificate la intrarea în România peste 150 de mașini furate de către polițiștii de frontieră [26]. Autovehiculele furate ar putea fi detectate mai facil prin utilizarea unor software-uri ANPR, fără a fi necesară introducerea într-o bază de date a unor informații din talonul autovehiculului.



Figură 3 – Numărul de mașini furate în România în perioada 2016-2021 [25]

“We can only see a short distance ahead, but we can see plenty there that needs to be done.”

“Putem vedea doar o mică distanță în viitor, dar putem vedea multe acolo care trebuie făcute.”

- Alan Turing, Computing machinery and intelligence [27].

Probleme sociale existente pe teritoriul României impun existența și utilizarea unor sisteme inteligente de detecție a numerelor de înmatriculare, dar și de detecție în timp real a potențialilor urmăritori din trafic. Deoarece societatea avansează într-un ritm alert, populația are nevoie de soluții rapide, inteligente, eficiente, care să fie bazate pe tehnologii actuale, de ultimă oră. Astfel, Inteligența Artificială joacă un rol important în soluționarea diferitelor probleme umane.

Noi, ca specie colectivă, am visat din totdeauna să creăm mașinării inteligente, capabile de a procesa informație și de a lua decizii singure. Odată cu progresele recente din cercetare, tehnologie și odată cu îmbunătățirea puterii de calcul, inteligența artificială (în engleză, Artificial Intelligence - AI), învățarea automată (în engleză, Machine Learning - ML) și învățarea profundă (în engleză, Deep learning – DL) au devenit un punct focal în rândul

tehnologilor și al populației extinse. Deși viitorul promis al Hollywood-ului este sub semne de întrebare încă, am început să vedem și să folosim frânturi ale sistemelor inteligente în viața noastră de zi cu zi. De la asistenți virtuali inteligenți, cum ar fi Google Now, Siri, Alexa sau Cortana, până la mașini cu conducere autonomă, acceptăm treptat astfel de tehnologii inteligente în rutina noastră zilnică.

„One day the Als are going to look back on us the same way we look at fossil skeletons on the plains of Africa. An upright ape living in dust with crude language and tools, all set for extinction.”

„Într-o zi, mașinările echipate cu Inteligență Artificială se vor uita înapoi la noi în același mod în care noi ne uităm la scheletele fosile de pe câmpiile Africii. O maimuță ce stă drept pe două picioare, care trăiește în praf, cu un limbaj grosolan și unelte grosolane, totul pregătit pentru a o conduce la dispariție.”

- Nathan Bateman, Ex Machina (Movie 2014) [28].

Trăim în „epoca datelor”, ce deține o putere de calcul mai bună și mai multe resurse de stocare. Aceste date sau informații cresc pe zi ce trece, dar adevărata provocare este să dăm sens tuturor datelor.

Învățarea automată (în engleză, Machine Learning - ML) schimbă rapid lumea, prin diverse tipuri de aplicații și cercetări efectuate în industrie și mediul academic. Învățarea automată afectează în mod pozitiv fiecare parte a vieții noastre de zi cu zi. De la asistenți virtuali și modele de învățare automată folosite pentru a ne verifica calendarul și a reda muzică, până la reclame personalizate (care sunt atât de precise încât pot prezice de ce vom avea nevoie înainte de a ne da noi seama), învățarea automată este un factor în viețile noastre de zi cu zi, în aproape orice moment.

Detecția Automată a Numerelor de Înmatriculare este un domeniu important de cercetare în domeniul Sistemelor Inteligente de Transport (în engleză, Intelligent transport Systems - ITS). Toate vehiculele din lume au plăcuțele de înmatriculare ca identificator principal. Cu dezvoltarea rapidă a tehnologiei de viziune artificială, metode robuste de detectare automată a obiectelor sunt introduse în ITS, iar o componentă integrală a domeniului ITS este Detecția Automată a Numerelor de Înmatriculare. [29]

Proiectul de față utilizează conceptele de Inteligență Artificială, Învățare Automată și Învățare prin Transfer pentru a crea un sistem inteligent, ce detectează nu doar numerele de înmatriculare, dar și potențialii urmăritori din trafic. Prin preluare de date în timp real, folosind un sistem Raspberry Pi, utilizatorul va primi alerte via sms/email cu privire la eventualele pericole reprezentate de alți participanți din trafic. De asemenea, va putea vizualiza datele preluate și procesate într-o interfață grafică.

1.2 OBSTACOLE

Tehnologia ANPR trebuie să țină cont de diferențele plăcuțelor de înmatriculare de la un loc la altul pentru recunoașterea optică a caracterelor (OCR). Când plăcuțele de înmatriculare olandeze au trecut la un stil diferit în 2002, una dintre modificările făcute a fost la font, introducându-se mici spații goale în unele litere (cum ar fi P și R) pentru a le face mai distincte și, prin urmare, mai lizibile pentru astfel de sisteme. Unele standarde naționale pentru realizarea numerelor de înmatriculare folosesc variații ale dimensiunilor fontului și ale poziționării, deci sistemele ANPR trebuie să poată procesa toate aceste diferențe pentru a fi cu adevărat eficiente. Sistemele mai complicate pot face față variantelor internaționale, dar majoritatea sistemelor sunt adaptate individual pentru fiecare țară [30].

În anii 1990, progresele semnificative ale tehnologiei au condus la evoluția sistemelor ANPR de la aplicații limitate, costisitoare și greu de configurat, pe bază de aplicații fixe, la aplicații mobile simple. Aceste progrese tehnologice le-au permis polițiștilor să patruleze zilnic cu beneficiul citirii plăcuțelor de înmatriculare în timp real.

În ciuda aparentei lor eficiențe, există totuși provocări demne de notat legate de sistemele mobile. Una dintre cele mai mari provocări este că procesorul și camerele trebuie să funcționeze suficient de repede pentru a face față unor viteze de deplasare de peste 160 km/h [13a]. Echipamentul de detecție automată trebuie să fie, de asemenea, foarte eficient din punct de vedere al consumului, deoarece sursa de alimentare este, de obicei, o baterie uzuală sau bateria vehiculului. Echipamentul trebuie să fie, în mod ideal, de dimensiuni mici, pentru a fi cât mai portabil.

Algoritmul folosit trebuie, de asemenea, să poată compensa toate variabilele ce pot afecta capacitatea sistemului de detecție de a produce o citire precisă, cum ar fi:

- Momentul zilei (dimineață, prânz, amurg, seară, noapte),
- Vremea (condiții meteo favorabile și nefavorabile),
- Unghiurile dintre camera sistemului și plăcuțele de înmatriculare de procesat,
- Rezoluția slabă a fișierului, de obicei deoarece numărul de înmatriculare se află la o distanță mare față de sistem,
- Imaginile captate neclare datorită faptului că sistemul funcționează asupra unor obiecte aflate în mișcare
- Iluminarea slabă și contrastul scăzut din cauza supraexpunerii, a reflexiei sau a umbrelor,
- Obstrucționarea numărului de înmatriculare de către un obiect, cum ar fi o bară de remorcare sau praf, noroi, zăpadă,
- Schimbarea direcției vehiculului în timpul citirii plăcuței de înmatriculare, de obicei în timpul unor viraje

Deși unele dintre aceste probleme pot fi corectate în pe partea de software, în general rezolvarea obstacolelor revine părții de hardware a sistemului. Creșterea înălțimii camerei poate înlătura, de exemplu, problema obiectelor care întunecă numărul de înmatriculare, dar introduce alte probleme, cum ar fi necesitatea reajustării poziției pentru înclinarea crescută a plăcii. Cele mai multe sisteme avansate din punct de vedere tehnic au o flexibilitate crescută și sunt configurabile, fiind posibilă configurarea unui mai mare număr de camere, uzual între una și patru camere, care pot fi aranjate cum este necesar.

Conceptul de confidențialitate a datelor a cauzat îngrijorări cu privire la ANPR, cum ar fi urmărirea guvernamentală a locației cetățenilor, identificarea greșită, ratele ridicate de eroare și creșterea cheltuielilor guvernamentale. Criticii au descris-o ca pe o formă de supraveghere în masă, susținând, de asemenea, că această tehnologie este folosită pentru a crește veniturile statului, nu pentru a promova siguranța [31].

În cadrul Uniunii Europene, GDPR este legea privind protecția datelor și confidențialitatea care se aplică tuturor persoanelor rezidente. Legea GDPR fost instituită la pentru a le permite cetățenilor Uniunii Europene să-și controleze datele personale. Instituirea acestei legi impune ca orice utilizator al tehnologiei ANPR, fie entități publice sau private, să informeze persoanele că sistemul există, să pună în aplicare o evaluare a riscurilor, să dea curs cererilor de date cu caracter personal, să asiste forțele de ordine atunci în diferite solicitări și să monitorizeze conformitatea pentru orice subcontractanți al produsului [32].

“The Best for the Group comes when everyone in the group does what's best for himself AND the group.”

„Situația cea mai bună pentru grup vine atunci când toată lumea din grup face ceea ce este mai bine pentru sine ȘI pentru grup.”

— John Nash

Realizând această lucrare și, implicit, consultând diferite opinii privind conceptul de ANPR, concluzia trasă a fost că trebuie ajuns la un compromis. Prelucrarea și stocarea datelor de către ANPR poate răni orgolii individuale și crea scenarii paranoice. În schimb, folosind această tehnologie, putem mări siguranța colectivă și individuală. Într-un scenariu ideal, unde legile sunt respectate, iar rata criminalității nu depășește pragul de nulitate, software-urile ANPR ar fi, fără loc de discuție, un abuz asupra vieții private. Însă, în realitatea cotidiană, acest tip de software-uri sporesc siguranța și obligă cetățenii la respectare legilor. Consider tehnologiile ANPR nu doar folositoare, ci necesare.

1.3 OBIECTIVE

Obiectivul principal este realizarea unui sistem inteligent de detecție a urmăritorilor în trafic, care ar putea fi transformat și folosit și în alte scopuri, cu alte opțiuni și facilități. Sporirea securității cetățeanului este prioritatea lucrării. Folosirea unui program modern, ce

ar putea fi portat și pe telefoane mobile, dar și integrat în cadrul altor aplicații deja existente, poate fi folosit de oricine, fie utilizatorul un organ al legii, sau un cetățean obișnuit.

1.4 STRUCTURA LUCRĂRII

În cadrul primului capitol, Introducere, se prezintă tema lucrării, istoricul conceptului de ANPR, contextul din care rezultă necesitatea sistemului propus, obstacolele generale și obiectivele propuse.

În continuare, în cel de al doilea capitol, Analiza și Specificarea Cerințelor Funcționale/Nefuncționale, sunt prezentate categoriile de utilizatori și cerințele de dezvoltare, împreună cu analiza SWOT.

Al treilea capitol, abordări existente, se concentrează asupra produselor comerciale similare existente deja pe piață și asupra algoritmilor uzuali pentru realizarea unui astfel de sistem.

Mai departe, în al patrulea capitol, Soluția Propusă, sunt descrise tehnologiile utilizate și arhitectura sistemului, iar realizarea propriu-zisă a sistemului este descrisă în capitolul cu numărul cinci, Detalii de Implementare.

Rezultatele sunt expuse în capitolul cu numărul șase, Evaluarea Rezultatelor, unde sunt prezentate procesul de testare și de evaluare.

Posibilele dezvoltări anterioare și stadiul actual al dezvoltării reprezintă punctul de încheiere, capitolul al șaptelea, Concluzii.

2. ANALIZA ȘI SPECIFICAREA CERINȚELOR FUNCȚIONALE

Am utilizat Analiza SWOT (Strengths, Weaknesses, Opportunities, Threats) pentru pasul de analiză și planificare a strategiei de dezvoltare. Cu ajutorul acestei analize (Figura 4), am determinat punctele tari, punctele slabe, oportunitățile și amenințările în legătură cu dezvoltarea sistemului. Pornind de la aceste puncte, au fost determinate cerințele pe care trebuie să le satisfacă proiectul, și anume să fie portabil, simplu de înțeles și folosit. Utilizatorul nu este obligat să introducă input-uri sistemului sau să înțeleagă concepte precum cele de Învățare Automată sau Procesare de Imagine.



Figură 4 – Analiza SWOT a sistemului

2.1 DESCRIEREA CATEGORIILOR DE UTILIZATORI

Categoria amplă de utilizatori este aceea a persoanelor ce vor să își îmbunătățească securitatea personală în trafic și nu numai. Spectrul larg cuprinde categoria populației române posesoare de carnet de conducere. Publicul țintă specific este cel al persoanelor ce ar putea folosi aplicația astfel:

- Cetățeni prevăzători, care vor să profite de orice tip de tehnologie ce le poate îmbunătăți securitatea,
- Cetățeni interesați de ultimele tehnologii în materie de gadget-uri,
- Companii ce vor să asigure securitatea mașinilor de serviciu oferite angajaților,
- Părinți ce vor să îmbunătățească siguranța copiilor în trafic, odată ce aceștia ating vârsta de 18 ani,
- Persoane ce sunt amenințate, care își doresc să fie avertizate asupra anumitor autovehicule întâlnite în trafic,
- Victime ale violenței domestice sau de alt tip, care necesită dovezi privind hărțuirea asupra căreia sunt supuse, dovezi ce pot facilita obținerea unui ordin de restricție.

Ar fi utilizat? Sondaj!

2.2 CERINȚE DE SISTEM (HARDWARE ȘI SOFTWARE)

Pentru a executa codul sursă (încărcarea setului de date, antrenarea modelului, procesul de detecție și interfața grafică), sunt necesare o cameră web și un computer ce are instalată varianta Python 3.10¹ sau o variantă superioară și o listă de pachete și framework-uri (cele principale fiind tensorflow², scipy³, protobuf⁴, GPUUtil⁵, avro-python3⁶, opencv-python⁷, numpy⁸, matplotlib⁹, easyocr¹⁰, pytorch¹¹, jupyter¹², Django¹³).

Computer-ul folosit este un Laptop Lenovo ThinkPad T14s, cu un procesor Intel Core i7-1165G7, cu 4 nuclee și o frecvență nominală de 2.8 GHz, cu o placă video integrată

¹ Python. Disponibil: <https://www.python.org/downloads/> [Accesat: 08.06.2022]

² Tensorflow. Disponibil: <https://www.tensorflow.org/> [Accesat: 08.06.2022]

³ SciPy. Disponibil: <https://scipy.org/> [Accesat: 08.06.2022]

⁴ Protobuf. Disponibil: <https://pypi.org/project/protobuf/> [Accesat: 08.06.2022]

⁵ GPUUtil. Disponibil: <https://pypi.org/project/GPUUtil/> [Accesat: 08.06.2022]

⁶ AvroPython3. Disponibil: <https://pypi.org/project/avro-python3/> [Accesat: 08.06.2022]

⁷ OpenCV. Disponibil: <https://pypi.org/project/opencv-python/> [Accesat: 08.06.2022]

⁸ NumPy. Disponibil: <https://numpy.org/> [Accesat: 08.06.2022]

⁹ Matplotlib. Disponibil: <https://matplotlib.org/> [Accesat: 08.06.2022]

¹⁰ EasyOCR. Disponibil: <https://github.com/JaidedAI/EasyOCR> [Accesat: 08.06.2022]

¹¹ Pytorch. Disponibil: <https://pytorch.org/> [Accesat: 08.06.2022]

¹² Jupyter. Disponibil: <https://jupyter.org/> [Accesat: 08.06.2022]

¹³ Django. Disponibil: <https://www.djangoproject.com/> [Accesat: 08.06.2022]

Intel Iris Xe, cu o capacitate a memoriei de 16 GB și un SSD cu capacitate de 512 GB, funcționând pe sistemul de operare Windows 10.

2.3 CERINȚE FUNCȚIONALE/NEFUNCȚIONALE

Cerințe funcționale:

- Sistemul trebuie să avertizeze utilizatorii via sms/email asupra posibilităților urmăritori din trafic
- Sistemul trebuie să aibă o interfață grafică minimală pentru vizualizarea detecțiilor

Cerințe nefuncționale:

- Sistemul trebuie să poată fi utilizat fără antrenarea modelului de către utilizator,
- Sistemul trebuie să permită antrenarea modelului folosind date noi.

2.4 MODELĂRI ALE SISTEMULUI

Modelarea sistemului are ca bază procesul de schimb de informații dintre aplicație și utilizator. Utilizatorul antrenează modelul (sau folosește modelul gata antrenat), oferă sistemului datele de contact pentru emiterea avertizărilor, iar aplicația oferă ieșirea sistemului (detecțiile, avertizările, interfața grafică) folosind modelul antrenat.

a) Actorii și Cazurile de Utilizare

Actorii reprezintă utilizatorii aplicației, acei utilizatori ce își doresc a primi avertizări cu privire la posibilele autoturisme ce îi urmăresc în trafic.

Cazurile de utilizare sunt:

- Antrenarea modelului
- Folosirea sistemului în scopul detecției urmăritorilor în trafic

b) Descrierea Cazuirilor de Utilizare ale Sistemului

1. Antrenarea modelului:

a) Precondiție: Software-ul este pornit.

b) Flux de bază:

- Se încarcă seturile de date de antrenare și testare în scopul prelucrării acestora,
- Se inițializează modelul,
- Se antrenează modelul,
- Se oferă datele de contact pentru emiterea de alerte.

c) Cazuri alternative:

- i. Seturile de date sunt invalide -> Eroare de execuție.
- ii. Parametrii modelului sunt incorecți -> Eroare de execuție.
- iii. Model neinițializat -> Eroare de execuție.

d) Rezultat – Modelul este antrenat, iar utilizatorul va putea primi atenționări cu privire la eventualii urmăritori din trafic.

2. Folosirea sistemului în scopul detecției urmăritorilor din trafic:

a) Precondiție: Software-ul este pornit, iar modelul este antrenat.

b) Flux de bază:

- i. Se oferă datele de contact pentru emiterea de alerte.

c) Rezultat – Utilizatorul primește atenționări cu privire la eventualii urmăritori din trafic și poate urmări detecțiile în interfața grafică.

3. ABORDĂRI EXISTENTE

3.1 PRODUSE COMERCIALE

Dacă pentru numerele de înmatriculare de pe teritoriul american există o multitudine de produse comerciale, prezentate în continuare, pentru numerele de înmatriculare române proiecte comerciale de acest tip nu sunt cunoscute.

Plate Recognizer¹⁴ este un produs software ce funcționează în orice mediu, optimizat pentru locația utilizatorului. Acest produs comercial returnează utilizatorului marca, modelul, culoarea, regiunea și direcția de deplasare a vehiculelor detectate. Detecția numărului de înmatriculare se poate face pe baza unei imagini sau folosind un flux de date video (chiar și în timp real). Plate Recognizer este destinat monitorizării parcarilor, autostrăzilor și colectării de taxe de drum. Serviciul de detecție în timp real, cu preluare de marcă, model, culoare, orientare și direcție de deplasare, plus accesul la interfața grafică ajunge la prețul de 60 de dolari americani pe lună, pentru un utilizator [32].

OPENALPR¹⁵ propune un sistem asemănător, al cărui preț ajunge la 1499 de dolari americani (sistemul video plus 1 an de utilizare a software-ului dedicat) [32].

Compania **Axis**¹⁶ propune sistemul AXIS P1455-LE-3 Plate Verifier Kit, pe care ei îl descriu ca fiind ieftin, deși funcționează perfect doar în condiții de viteză relativ mică. Sistemul, de tip fix, detectează numărul de înmatriculare și trimite o comandă pe baza acestuia (exemplu: deschidere poartă sau alertă mașină necunoscută). Produsul, pe site-ul devodep.ro, are prețul de 5692 RON [33].

Compania **Leonardo**¹⁷ a dezvoltat soluția mobilă ELSAG Mobile Plate Hunter, care declanșează alerte cu privire la vehicule marcate anterior din baza de date. Acest produs funcționează, însă, perfect doar pentru vehiculele înmatriculate în Statele Unite ale Americii și pentru alte câteva țări [34].

Prețul oficial nu este afișat pe site-ul acestora, însă variante la mână a doua se comercializează pe ebay.com la prețul de aproximativ 270 de dolari americani [35].

Piața de sisteme pentru detecția numerelor de înmatriculare este nu doar performantă, dar și competitivă în spațiul american. Numitorul comun al tuturor aceste

¹⁴ Plate Recognizer. Disponibil: <https://platerecognizer.com/> [Accesat: 08.06.2022]

¹⁵ OpenALPR. Disponibil: <https://www.openalpr.com/> [Accesat: 08.06.2022]

¹⁶ Axis. Disponibil: <https://www.axis.com/> [Accesat: 08.06.2022]

¹⁷ Leonardo. Disponibil: <https://leonardocompany-us.com/> [Accesat: 08.06.2022]

sisteme comerciale existente este prețul ridicat, inaccesibil pentru utilizatorul român. Astfel, piața de servicii software și produse fizice pentru detecția numerelor de înmatriculare române prezintă un potențial pentru dezvoltatorii din industria IT și Automotive.

3.2 METODE EXISTENTE

Există șapte algoritmi principali ce sunt folosiți, în general, pentru realizarea software-ului de identificare a unei plăcuțe de înmatriculare:

- Algoritmul de localizare a plăcuței de înmatriculare – responsabil pentru găsirea și izolarea numărului de înmatriculare de pe imagine,
- Algoritmul de corecție pentru orientarea și dimensionarea plăcuței de înmatriculare - compensează înclinarea numărului de înmatriculare și ajustează dimensiunile la dimensiunea necesară,
- Algoritmul de normalizare – se ocupă cu ajustarea luminozității și a contrastului imaginii captate,
- Algoritmul de segmentare optică a caracterelor – are rolul de identifica fiecare caracter alfanumeric individual de pe numărul de înmatriculare,



Figură 5 – Exemplu de segmentare a caracterelor [5]

- Algoritmul de recunoaștere optică a caracterelor – are scopul de a traduce fiecare caracter detectat pe plăcuța de înmatriculare,
- Algoritmul de analiză sintactică/geometrică – se ocupă de verificarea caracterelor și a pozițiilor acestora în raport cu regulile specifice fiecărei țări,
- Algoritmul de mediere a valorii recunoscute pe mai multe imagini – cu scopul de a produce un rezultat cu o acuratețe ridicată, luând în considerare faptul că fiecare imagine capturată poate conține o lumină reflectată, poate fi parțial umbrită sau poate fi obstrucționată din diverse motive [13a].


4. SOLUȚIA PROPUȘĂ

4.1 Tehnologii utilizate

Lucrarea de față folosește Python¹⁸, Tensorflow¹⁹, Învățarea Automată și o multitudine de pachete, biblioteci și Framework-uri Python pentru a implementa soluția propusă.

Sistemul de operare utilizat este Windows 10²⁰. Am folosit, de asemenea, acolo unde era cazul, posibilitatea de a rula instrucțiuni specifice sistemului de operare Linux, pentru a îmbunătăți portabilitatea aplicației.

Învățarea automată (în engleză, Machine Learning – ML) este un vast domeniu al informaticii ce utilizează tehnici statistice pentru a le oferi programelor abilitatea de a învăța din experiențele trecute și de a îmbunătăți modul în care îndeplinesc anumite sarcini, fără a fi programate în mod explicit și fără intervenție umană.



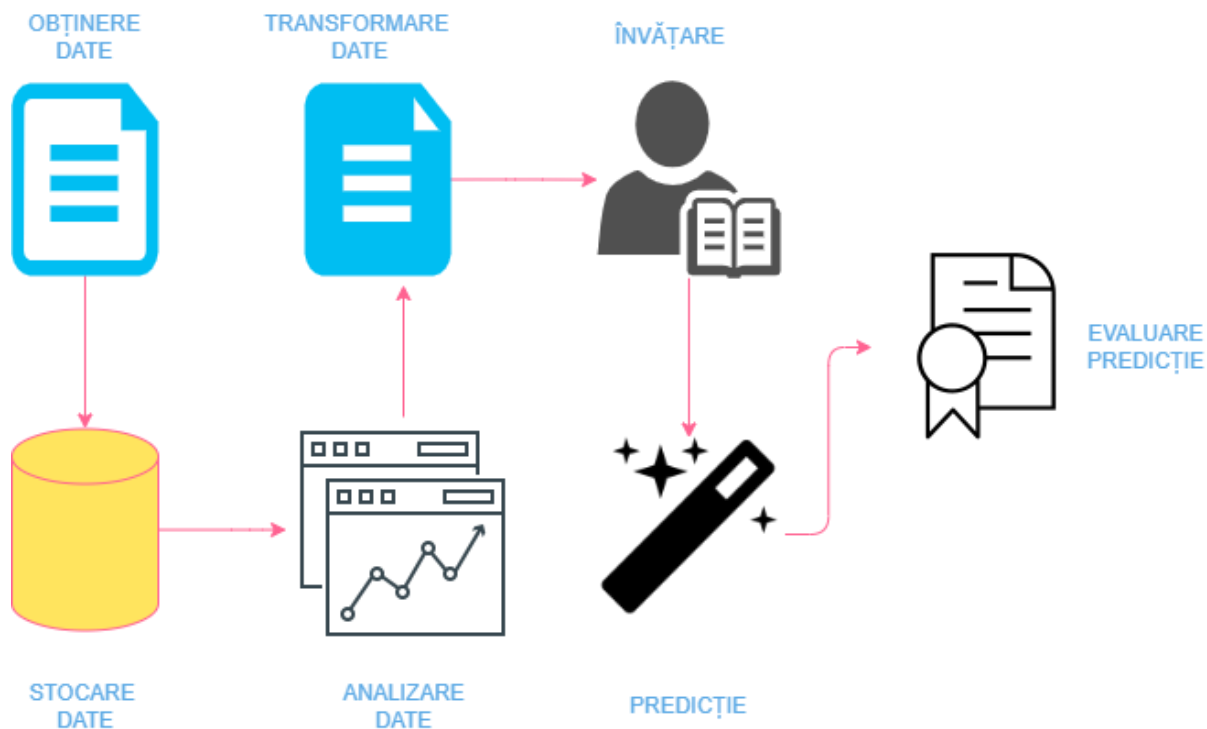
Figură 6 – Procesul de Învățare automată

¹⁸ Python. Disponibil: <https://www.python.org/> [Accesat: 08.06.2022]

¹⁹ Tensorflow. Disponibil: <https://www.tensorflow.org/> [Accesat: 08.06.2022]

²⁰ Windows 10. Disponibil: <https://www.microsoft.com/ro-ro/windows/windows-10-specifications> [Accesat: 08.06.2022]

Practic, sistemele informatice pot oferi un sens datelor în același mod în care o ființă umană ar face același lucru. Astfel, programele de tip ML construiesc modele matematice din date brute folosind algoritmi și metode, iar, pe baza acestor modele, realizează predicții.



Figură 7 – Procesul de învățare automată (detalii)

"Can machines think?"

„Pot mașinăriile să gândească?”

- Alan Turing, "Computer Machinery and Intelligence," 1950 [27]

“A computer program is said to learn from experience E with respect to some class of tasks T and performance measure P, if its performance at tasks in T, as measured by P, improves with experience E.”

„Se spune că un program de calculator învață din experiența E cu privire la o anumită clasă de sarcini T și cu măsura performanței P, dacă performanța sa la sarcinile din T, măsurată de P, se îmbunătățește cu experiența E.”

- Tom M. Mitchell [36]

Transfer Learning: Modelelor de rețele neuronale convoluționale profunde le pot fi necesare zile sau chiar săptămâni pentru a se antrena pe seturi de date foarte mari. O modalitate de a scurta acest proces este de a reutiliza modele pre-antrenate, care au fost dezvoltate pentru seturi de date standard de Computer Vision. Modele performante (uzual, antrenate pe seturi de date mari) pot fi descărcate și utilizate direct sau integrate într-un model. Astfel, învățarea prin transfer implică utilizarea modelelor instruite pe o problemă ca

punct de plecare pentru o altă problemă conexasă. Conceptul de Transfer Learning este foarte util în momentul în care problema de tratat are un set de date minimal.

Învățarea prin transfer este flexibilă. Modelul pre-antrenat poate fi folosit ca un program separat de extragere a caracteristicilor, caz în care input-ul poate fi preprocesat de model sau de către o porțiune a modelului la un output dat pentru fiecare imagine de intrare, care poate apoi fi utilizată ca intrare atunci când este antrenat un model nou [37].

Alternativ, modelul pre-antrenat sau porțiunea dorită a modelului poate fi integrată direct într-un nou model de rețea neuronală. În această utilizare, ponderile pre-antrenate pot fi înghețate, astfel încât să nu fie actualizate pe măsură ce noul model este antrenat. Alternativ, ponderile pot fi actualizate în timpul antrenării noului model, dar eventual cu o rată de învățare mai mică, permițând modelului pre-antrenat să acționeze ca o schemă de inițializare a ponderilor atunci când antrenează noul model [37].

Python²¹ este un limbaj de programare interpretat, cu sursă deschisă, gratuit, popular, care are capacitățile unui limbaj de programare de nivel înalt. Sintaxa ușor de învățat și capacitatea de portabilitate îi oferă o mare popularitate în zilele noastre.

Python are o mulțime de puncte forte, printre care și:

- Este ușor de învățat și de înțeles, dispunând de o sintaxă simplă.
- Este un limbaj multifuncțional, deoarece acceptă programarea structurală, programarea orientată pe obiecte, precum și programarea funcțională.
- Dispune de un număr mare de module ușor disponibile pentru utilizare, transformând Python într-un limbaj extensibil.
- Dispune de un suport mare al pentru comunității open source - Fiind un limbaj de programare open source, Python este susținut de o comunitate foarte mare de dezvoltatori.
- Este un limbaj scalabil, deoarece oferă o structură îmbunătățită pentru programele mai mari decât scripturile shell.

Cu toate acestea, deși Python este un limbaj de programare popular și puternic, are propria sa slăbiciune, aceasta fiind reprezentată de viteză lentă de execuție. Această viteză lentă de execuție rezultă din faptul că Python este un limbaj interpretat, și nu unul compilat.

Python ne oferă posibilitatea de a crea un program de detecție și recunoaștere a numerelor de înmatriculare, deoarece are un set extensiv de pachete gata de folosit, multe reprezentând un mare ajutor în domeniul ML, precum Numpy²², Seaborn²³, Matplotlib²⁴, Pandas²⁵ și Scikit-learn²⁶. De asemenea, Python este potrivit aplicațiilor de tip ML, deoarece, cu ajutorul acestuia, putem manipula și analiza date, extrage parametrii datelor,

²¹ Python. Disponibil: <https://www.python.org/> [Accesat: 08.06.2022]

²² Numpy. Disponibil: <https://numpy.org/> [Accesat: 09.06.2022]

²³ Seaborn. Disponibil: <https://seaborn.pydata.org/> [Accesat: 09.06.2022]

²⁴ Matplotlib. Disponibil: <https://matplotlib.org/> [Accesat: 09.06.2022]

²⁵ Pandas. Disponibil: <https://pandas.pydata.org/> [Accesat: 09.06.2022]

²⁶ Scikit-learn. Disponibil: <https://scikit-learn.org/stable/> [Accesat: 09.06.2022]

manipula, evalua și îmbunătăți datele. Așadar, realizăm aplicația folosind Python și mai multe dintre bibliotecile sale.

Mediul de dezvoltare folosit a fost Pycharm IDE²⁷, deoarece este disponibil gratuit, are facilități suplimentare la conectarea cu adresa de email academică, are integrat sistemul de versionare git și este potrivit pentru utilizatorii Windows sau Linux.

De asemenea, am folosit Jupyter²⁸. Notebook-urile Jupyter oferă un mediu computațional interactiv web pentru dezvoltarea aplicațiilor Data Science bazate pe Python. Jupyter Notebook-urile ilustrează procesul de analiză pas cu pas prin aranjarea elementelor precum codul, imaginile, textul, rezultatele etc.

Jupyter Notebook se poate conecta la multe nuclee pentru a permite programarea în diferite limbi. Un nucleu Jupyter este un program responsabil pentru gestionarea diferitelor tipuri de solicitări (precum execuția codului) și furnizarea unui răspuns. Spre deosebire de multe alte interfețe asemănătoare notebook-urilor, în Jupyter, nucleele nu știu că sunt atașate la un anumit document și pot fi conectate la mai mulți clienți simultan. În mod implicit, Jupyter Notebook este livrat cu nucleul IPython.

Pentru a izola diversele pachete necesare, am creat un environment virtual. Acest environment face mult mai facilă gestionarea dependențelor proiectului. Virtual environment-ul a fost asociat unui ipykernel folosit pentru rularea celulelor de cod din cadrul Jupyter Notebook-ului.

OpenCV²⁹ (Open Source Computer Vision Library) este o bibliotecă de învățare automată cu sursă deschisă, multiplatformă, ce oferă o infrastructură de bază pentru domeniul Computer Vision. Cu ajutorul OpenCV, pot fi realizate aplicații de conducere autonomă, adnotare a imaginilor, monitorizarea în timp real a recoltelor pe bază de drone, etc.

OpenCv se concentrează, în principal, pe captarea de imagini și fișiere video, pentru a analiza caracteristici importante din cadrul acestora, cum ar fi detecția de obiecte, detecția de fețe umane, detecția de emoții, etc. De asemenea, OpenCV este un modul ce facilitează procesarea rapidă, deoarece codul său sursă este bazat pe C/C++ [38].

Astfel, OpenCv joacă un rol principal în aplicațiile de inteligență artificială bazate pe procesarea imaginilor.

Recunoașterea automată textului (cunoscută și ca recunoașterea optică a caracterelor) este procesul de recunoaștere a textului dintr-un anumit scenariu prin înțelegerea și analiza modelelor sale subiacente [39].

²⁷ Pycharm. Disponibil: <https://www.jetbrains.com/pycharm/> [Accesat: 08.06.2022]

²⁸ Jupyter. Disponibil: <https://jupyter.org/> [Accesat: 08.06.2022]

²⁹ OpenCV. Disponibil: <https://pypi.org/project/opencv-python/> [Accesat: 08.06.2022]



Figură 8 – Procesul de Recunoaștere Automată a Caracterelor

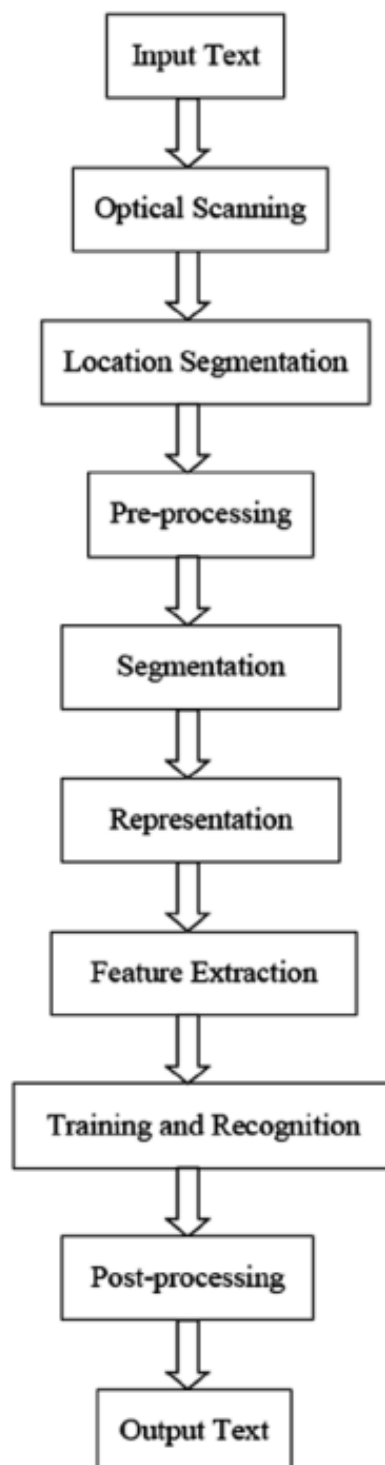
Cu alte cuvinte, sistemele OCR transformă o imagine bidimensională, care ar putea conține text tipărit sau scris de mână, din reprezentarea de tip imagine într-un text care poate fi citit de către o mașinărie. Din acest motiv, OCR este, de asemenea, recunoscut ca un subdomeniu al procesării de imagine. [40]

OCR, ca proces, constă, în general, din mai multe subprocesse ce trebuie a fi realizate cât mai precis posibil.

Subprocesele acestea sunt, uzual:

- încărcarea imaginii ca input,
- scanarea imaginii (convertirea elementelor din imagine într-o matrice bidimensională de puncte albe și negre),
- localizarea zonelor de interes (zonele textului),
- preprocesarea imaginii (eliminarea zgomotului, umplerea golurilor, normalizarea și compresia imaginii),
- segmentarea caracterelor,
- recunoașterea caracterelor,
- postprocesarea rezultatului [41].

Pentru realizarea unui model de învățare automată de recunoaștere a caracterelor, sunt inserați și pașii de reprezentare, extragere de caracteristici, antrenare și testare. [40]



Figură 9 – Subprocese pentru realizarea unui model de Recunoaștere optică a caracterelor [40]

Recunoașterea optică a caracterelor poate fi folosită în diverse aplicații, cum ar fi citirea documentelor, preluarea informațiilor scrise de mână, identificarea produselor de pe rafturi, audierea textului pentru persoanele cu dificultăți vizuale, detectarea semenelor de circulație și a mesajelor acestora pentru conducerea autonomă și multe altele [39].

Deși este folosit în multiple domenii și aplicații, OCR prezintă, încă, unele dificultăți, ce împiedică performanța. Sursa (documentul, imaginea), în cazul în care este degradată, aduce obstacole în procesarea OCR. Unele dintre caracteristicile de calitate joasă comune sunt iluminarea scăzută, contrastul insuficient între prim-plan și fundal, rezoluția scăzută, caracterele cu aspect șters, zgomotul suprapus peste imaginea captată, etc.

EasyOCR³⁰ este o librărie OCR optimizată pentru Python pentru extragerea textului din fișiere imagine.

SciPy³¹ este un pachet Python gratuit, cu sursă deschisă, folosit pentru calcule computaționale științifice și tehnice. Conține module pentru optimizare, pentru algebră liniară, pentru integrare, interpolare, transformări, procesare de imagine și de semnal și multe alte sarcini ingineresti.

PIL/Pillow³² (Python Imaging Library) este o librărie gratuită pentru limbajul de programare Python, ce oferă suport pentru manipularea a multiple formate de imagine. Biblioteca Pillow conține funcționalități de bază de procesare a imaginilor, inclusiv operațiuni de filtrare cu un set de nuclee de convoluție încorporate și conversii în spații de culoare.

NumPy³³ (Numerical Python) este o librărie specifică limbajului Python, ce oferă suport pentru operații computaționale asupra unor matrice și vectori multidimensionali. Operații importante din cadrul pachetului NumPy sunt transformările Fourier și operații de algebră liniară. O imagine, în esență, este o matrice bidimensională sau tridimensională ce conține pixeli. Prin urmare, folosind operații de bază incluse în pachetul NumPy, precum slicing, mascare și indexare, se pot modifica valorile pixelilor unei imagini. Imaginea poate fi încărcată folosind modulul skimage și ulterior afișată folosind modulul Matplotlib.

Matplotlib³⁴ este librăria specifică Python și NumPy pentru realizarea de grafice bidimensionale și tridimensionale.

Pandas³⁵ este pachetul Python ce face Python să fie unul dintre limbajele de programare favorite pentru Data science. Pandas este folosit pentru încărcarea, pregătirea, manipularea, modelarea și analiza datelor. Reprezentarea datelor în Pandas se face cu ajutorul a trei structuri de date (serii, data frame-uri și panel-uri). Am folosit data frame-uri,

³⁰ EasyOCR. Disponibil: <https://github.com/JaidedAI/EasyOCR> [Accesat: 08.06.2022]

³¹ SciPy. Disponibil: <https://scipy.org/> [Accesat: 08.06.2022]

³² Pillow. Disponibil: <https://pypi.org/project/Pillow/> [Accesat: 08.06.2022]

³³ NumPy. Disponibil: <https://numpy.org/> [Accesat: 08.06.2022]

³⁴ Matplotlib. Disponibil: <https://matplotlib.org/> [Accesat: 08.06.2022]

³⁵ Pandas. Disponibil: <https://pandas.pydata.org/> [Accesat: 08.06.2022]

ce reprezintă o structură de date bidimensională, ce conține date eterogene. Data frame-urile sunt folosite, în general, pentru a reprezenta date tabulare (tabele).

PyTorch³⁶ este o bibliotecă populară de învățare automată Python, bazată pe Torch și dezvoltată de Facebook. Torch este o bibliotecă open-source de învățare automată implementată în limbajul de programare C [42].

PyTorch deține o selecție vastă de instrumente și biblioteci ce extind domeniile de Computer Vision, procesarea limbajului natural (în engleză, Natural Language Processing - NLP) și o serie de alte programe de învățare automată [42].

Tensorflow³⁷ este biblioteca de bază open source pentru dezvoltarea și antrenarea de modele ML, creată de Google. TensorFlow este o platformă open source end-to-end pentru învățarea automată. Are un ecosistem cuprinzător și flexibil de instrumente, biblioteci și resurse ale comunității, care permit cercetătorilor să promoveze tehnici de ultimă generație în ML, iar dezvoltatorilor să construiască și să implementeze cu ușurință aplicații bazate pe ML [43].

De asemenea, dispune de o arhitectură flexibilă, ceea ce înseamnă că poate fi implementat pe o mare varietate de platforme, de la procesoare și GPU-uri, până la servere de pe dispozitive mobile [44].

³⁶ Pytorch. Disponibil: <https://pytorch.org/> [Accesat: 08.06.2022]

³⁷ Tensorflow. Disponibil: <https://www.tensorflow.org/> [Accesat: 08.06.2022]

5. DETALII DE IMPLEMENTARE

Soluția a fost implementată într-un Jupyter Notebook, cu apel la script-uri Python și folosind framework-ul Django³⁸ pentru interfața grafică. Codul a fost scris în Python3, folosindu-se pentru calcule și operații matematice biblioteca NumPy (pe lângă operațiile puse la dispoziție de TensorFlow), iar pentru diferite reprezentări grafice folosindu-se biblioteca Matplotlib.

Modelul folosit este modelul SSD MobileNet V2 FPNLite 320x320³⁹, preantrenat pe setul de date COCO 2017⁴⁰.

Modelul este un model de detecție de obiecte cu următorii parametrii:

- Cu o abordare SSD (Single Shot MultiBox Detector), ce mărește viteza de procesare eliminând din rețeaua de propunere de regiune,
- Potrivită pentru aplicații mobile,
- Cu o caracteristică de extragere a datelor FPN (Feature Pyramid Network) – Caracteristică de Rețea Piramidală, ce oferă un flux de execuție de sus în jos pentru a construi straturi de rezoluție mai mare dintr-un strat bogat semantic,
- Cu facilitate de predicție pe bază de adnotări bounding box (casetă de încadrare).


FPN este un model de tip Analiza la scară multiplă, o idee destul de veche în procesarea imaginilor, ce a fost implementată în diferite arhitecturi de rețele neuronale. Unul dintre cele mai proeminente modele de acest fel a fost propus de Lin și colab. care au dezvoltat modelul în principal pentru detecția de obiecte, însă modelul a ajuns să prezinte o mare importanță în domeniul segmentării de imagine [45].

O arhitectură multistrat piramidală de Rețele Neuronale Convoluționale profunde a fost folosită pentru a construi această rețea piramidală. Pentru a întruni caracteristici de rezoluții scăzute și ridicate, rețeaua piramidală este compusă dintr-o cale de jos în sus, o cale de sus în jos și conexiuni laterale. Caracteristicile concatenate sunt, mai apoi, procesate de un strat convoluțional (filtru convoluțional îmbinat cu matricea de intrare, folosite împreună pentru antrenarea ponderilor) de mărime 3 pe 3 pentru a produce rezultatul fiecărei etape. În cele din urmă, fiecare etapă parcursă a căii de sus în jos generează o predicție pentru detecția unui obiect [46].

³⁸ Django. Disponibil: <https://www.djangoproject.com/> [Accesat: 08.06.2022]

³⁹ SSD MobileNet V2 FPNLite 320x320 Disponibil: http://download.tensorflow.org/models/object_detection/tf2/20200711/ssd_mobilenet_v2_fpnlite_320x320_co17_tpu-8.tar.gz [Accesat: 08.06.2022]

⁴⁰ COCO. Disponibil: <https://cocodataset.org/#home> [Accesat: 08.06.2022]



Figură 10 – Conexiunea laterală și calea de sus în jos, îmbinate prin însumare [45]

Modelul realizează următorii pași principali:

- Extragerea caracteristicilor (procesul de transformare a datelor brute în caracteristici numerice, care pot fi procesate, păstrându-se în același timp informațiile din setul de date original),
- Codificarea casetelor de încadrare (modelul de învățare automată primește o imagine ca intrare și, pe baza acesteia, generează o propoziție care descrie o imaginea și casetele de încadrare prezente în aceasta),
- Potrivirea (procesul prin care se compară diferite valori de date în format structurat sau nestructurat, pe baza similitudinii sau a unei entități subiacente),
- Calculul similitudinii (se utilizează abordarea a celui mai apropiat vecin pentru a identifica asemănarea a două sau mai multe obiecte unul cu celălalt pe baza funcțiilor algoritmice de distanță),
- Generarea variabilelor de casete de predicție (variabilele care sunt mapate la variabila țintă printr-o relație empirică determinată prin date),
- Generarea ancorelor (ancorele utilizează tehnici de învățare prin consolidare în combinație cu un algoritm de căutare bazat pe grafuri pentru a reduce numărul de apelări ale modelului și, prin urmare, timpul de rulare necesar, la minimum),
- Postprocesarea (îmbunătățirea calității imaginilor produse de către decodorul unui sistem de compresie a imaginilor cu pierderi),
- Calculul pierderii.

Preantrenarea modelului este realizată pe un număr de 50000 de pași, cu 128 de imagini procesate pe iterație, folosind un optimizator de tip momentum, ce modifică atributele rețelei neuronale (ponderile, rata de învățare) cu scopul de a minimiza pierderile și de a îmbunătăți precizia.

Setul de date folosit pentru antrenarea și testarea modelului se numește Car License Plate Detection⁴¹, ce conține 433 de imagini cu vehicule și adnotări în formatul PASCAL VOC.

Înainte de realizarea propriu-zisă a codului, am început cu procesul de setup, în care am creat directorul necesar, un virtual environment, am făcut upgrade la utilitarul PIP și am instalat pachetul ipykernel.

Am asociat un fișier de tip Jupyter Notebook cu environment-ul creat, am lansat în execuție jupyter și am setat kernel-ul folosit ca fiind virtual environment-ul creat.

În final, am stabilit anumite constante pentru a determina existența unui cod cât mai clar, concis și curat.

De asemenea, am descărcat un Dataset gratuit de pe site-ul kaggle.com, Dataset numit Car License Plate Detection.

Acest Dataset l-am împărțit în două categorii, antrenare și testare (411 imagini pentru antrenare și 22 pentru testare).

În pasul 1 al proiectului, am clonat un repository existent, deoarece dorim folosirea unui model existent preantrenat, pe care îl adaptăm cazului nostru. Această abordare este cunoscută sub numele de Transfer Learning.

Urmează instalarea Tensorflow Object Detection și rularea unui script de verificare pentru a ne asigura că avem minimul de pachete necesare pentru rularea codului în continuare.

După descărcarea modelului preantrenat, în pasul 2 creăm un Label Map. În cazul de față, avem un singur label, numărul de înmatriculare.

În pasul 3, ne ocupăm de crearea unor fișiere de tip Tensorflow records, necesare pentru configurarea și reantrenarea modelului.

Deoarece modelul descărcat este sub forma unui config file, în pasul 4 ne ocupăm de copierea acestui fișier de configurare, iar, în pasul 5, îl reconfigurăm pentru cazul nostru de utilizare.

În pasul 6, generăm comanda de antrenare a modelului, pe care o vom folosi într-o fereastră de cmd, pentru a vizualiza mai bine progresul procesului de antrenare. Am antrenat modelul folosind un număr de 10000 de pași. La fiecare 1000 de pași realizați, se creează un checkpoint. Vom folosi ultimul checkpoint creat pentru a detecta numere de înmatriculare folosind imagini (pasul 8), dar și în timp real (pasul 9), cu flux de date de la o cameră video.

⁴¹ Car License Plate Detection . Disponibil: <https://www.kaggle.com/datasets/andrewmvd/car-plate-detection?resource=download> [Accesat: 08.06.2022]

Pasul de redimensionare a imaginii ne ajută să evităm orice probleme referitoare la imaginile cu rezoluție mai mare, asigurându-ne că plăcuța de înmatriculare rămâne în continuare în cadru după redimensionare [47].

Am redimensionat fișierul imagine cu un factor de 2x atât în direcția orizontală, cât și în cea verticală folosind `cv2.resize`.

```
resize_test_license_plate = cv2.resize(  
    test_license_plate, None, fx = 2, fy = 2,  
    interpolation = cv2.INTER_CUBIC)
```

Convertirea imaginii în tonuri de gri este o practică destul de comună în toate etapele de procesare a imaginii. Acest lucru accelerează alte procese următoare [47].

Convertim imaginea redimensionată în tonuri de gri pentru a optimiza detecția și a reduce numărul de culori prezente în imagine drastic, ceea ce va ajuta, mai departe, în detectarea mai facilă a numerelor de înmatriculare.


În general, orice imagine va avea informații utile și inutile. În cazul de față, doar plăcuța de înmatriculare reprezintă informație utilă, ce poate fi afectată de zgomot. Utilizăm un filtru bilateral pentru a elimina detaliile nedorite dintr-o imagine [47].

6. EVALUAREA REZULTATELOR

Intersecția peste Uniune (în Engleză, Intersection over Union – IoU) este o metrică de evaluare utilizată pentru a măsura acuratețea unui detector de obiecte pe un anumit set de date. Orice algoritm care furnizează casete de delimitare prezise ca ieșire poate fi evaluat folosind IoU [48].

Pentru a aplica IoU pentru a evalua un detector de obiecte, avem nevoie de:

- Casetele de delimitare a adevărului de bază (adică acele casete de delimitare etichetate manual din setul de testare care specifică unde se află în imagine obiectul căutat),
- Casetele de delimitare prezise de către modelul nostru.



Figură 11 - Un exemplu de detectare a unui indicator de oprire într-o imagine. Caseta de delimitare prezisă este desenată cu roșu, în timp ce caseta de delimitare a adevărului de bază este desenată în verde [48].

Pentru a calcula IoU, este de ajuns să împărțim suprafața de suprapunere la suprafața de uniune.

$$IoU = \frac{\text{Suprafața de suprapunere}}{\text{Suprafața de uniune}} \quad (1)$$



Figură 12 – Suprafața de suprapunere [48]



Figură 13 – Suprafața de uniune [48]

Fiecare IoU are mapat precizia medie și factorul mediu de Recall. Precizia măsoară cât de exacte sunt predicțiile realizate, adică procentajul previziunilor corecte. Recall-ul măsoară cât de bine au fost determinate predicțiile pozitive [49]. Formulele pentru Precizie și Recall:

$$TP = \text{Adevărat pozitiv} \quad (2)$$

$$TN = \text{Adevărat negativ} \quad (3)$$

$$FP = \text{Fals pozitiv} \quad (4)$$

$$FN = \text{Fals negativ} \quad (5)$$

$$\text{Precizie} = \frac{TP}{TP+FP} \quad (6)$$

$$\text{Recall} = \frac{TP}{TP+FN} \quad (7)$$

IoU	area	maxDets	Average Precision
0.50:0.95	all	100	0.533
0.5	all	100	0.901
0.75	all	100	0.535
0.50:0.95	small	100	0.134
0.50:0.95	medium	100	0.66
0.50:0.95	large	100	0.751


Tabel 2 – Precizia medie în funcție de IoU

IoU	area	maxDets	Average Recall
0.50:0.95	all	1	0.6
0.50:0.95	all	10	0.6
0.50:0.95	all	100	0.6
0.50:0.95	small	100	0.133
0.50:0.95	medium	100	0.75
0.50:0.95	large	100	0.8


Tabel 3 – Recall-ul mediu în funcție de IoU

Step	10000
DetectionBoxes_Precision/mAP	0.53269
DetectionBoxes_Precision/mAP@.50IOU	0.90099
DetectionBoxes_Precision/mAP@.75IOU	0.534653
DetectionBoxes_Precision/mAP (small)	0.133663
DetectionBoxes_Precision/mAP (medium)	0.659736
DetectionBoxes_Precision/mAP (large)	0.751485
DetectionBoxes_Recall/AR@1	0.6
DetectionBoxes_Recall/AR@10	0.6
DetectionBoxes_Recall/AR@100	0.6
DetectionBoxes_Recall/AR@100 (small)	0.133333
DetectionBoxes_Recall/AR@100 (medium)	0.75
DetectionBoxes_Recall/AR@100 (large)	0.8
Loss/localization_loss	0.200382
Loss/classification_loss	0.391242
Loss/regularization_loss	0.122457
Loss/total_loss	0.714081


Tabel 4 – Precizia medie, recall-ul mediu și pierderile în funcție de IoU, la pasul 10000




Figură 14 - Precizia medie, recall-ul mediu și pierderile în funcție de IoU, la pasul 10000




Figură 15 – Rata de învățare, Pierdere de clasificare, Pierdere de localizare, Pierdere de regularizare și Pierdere totală, în funcție de pasul de antrenare




Figură 16 - Rata de învățare în funcție de pasul de antrenare




Figură 17 - Pierderea de clasificare în funcție de pasul de antrenare



Figură 18 - Pierderea de localizare în funcție de pasul de antrenare



Figură 19 – Pierderea de regularizare în funcție de pasul de antrenare



Figură 20 – Pierdere totală în funcție de pasul de antrenare

6.1 TESTARE

6.2 EVALUARE

Una dintre provocările cele mai mari privind realizarea unui sistem ANPR implică găsirea unui set de date ce poate fi utilizat pentru a antrena un model de învățare automată [50].

Adesea, nu modelul instruit este valoros, ci setul de date pe care o anumită companie l-a organizat. Seturi de date ANPR de dimensiuni largi și robuste pentru antrenare și testare sunt dificil de obținut, deoarece aceste seturi de date conțin informații sensibile, cu caracter personal, iar diversele companii și entități guvernamentale ce dețin astfel de seturi de date nu doresc a le împărtăși din motive de competitivitate [51].

7. CONCLUZII

7.1 UTILITATE

Ce am realizat în această lucrare.
Ce alte utilizări poate avea?

7.2 DEZVOLTĂRI ULTERIOARE

„If you want to make an apple pie from scratch, you must first create the universe”
„Dacă vrei să faci o plăcintă cu mere de la zero, trebuie mai întâi să creezi universul”
- Carl Sagan

Dezvoltarea și îmbunătățirea nu doar a modelului de detecție automată a urmăritorilor din trafic, ci și a domeniului recunoașterii automate a numerelor de înmatriculare este impetuos necesară.

Natural, primul pas în cadrul unor dezvoltări ulterioare ar fi îmbunătățirea acurateței detecțiilor și a recunoașterii caracterelor. Tehnologiile vor continua să avanseze, iar metodele folosite în acest proiect vor putea fi actualizate, conducând la îmbunătățirea modelului.

Al doilea pas către un proiect mai performant ar fi maximizarea vitezei de procesare.

De îmbunătățit ar fi și interfața grafică, ce ar putea fi mai user-friendly, mai atractivă și mai completă.

Un factor ce ar ajuta performanțele proiectului ar fi un dataset extins.

Integrarea unor API-uri.

Retinerea locației unei detecții.

Pe lângă actualizarea și îmbunătățirea modelului, dezvoltări viitoare ale sistemului pot include folosirea unor interfețe pentru interacțiunea dintre utilizator și program. Este necesar ca aplicația să poată fi folosită din cadrul a diferite sisteme de operare, precum iOS⁴², macOS⁴³, Android⁴⁴, Linux⁴⁵ sau Microsoft Windows⁴⁶.

De asemenea, proiectul poate constitui baza pentru alte aplicații, precum sisteme de monitorizarea a traficului, a semafoarelor dintr-o localitate, monitorizare a unei parări inteligente, ș.a.

⁴² iOS. Disponibil: <https://www.apple.com/ios/ios-15/> [Accesat: 08.06.2022]

⁴³ macOS. Disponibil: <https://www.apple.com/ro/macOS/what-is/> [Accesat: 08.06.2022]

⁴⁴ Android. Disponibil: <https://www.android.com/> [Accesat: 08.06.2022]

⁴⁵ Linux. Disponibil: <https://www.linux.org/> [Accesat: 08.06.2022]

⁴⁶ Windows. Disponibil: <https://www.microsoft.com/ro-ro/windows> [Accesat: 08.06.2022]

Anexă – Cod

Codul sursă dezvoltat în cadrul proiectului, alături de documentație, seturi de date și alte documente este disponibil în repository-ul public de la următoarea adresă:

🔗 <https://github.com/nasteeex/Licenta>

Adițional, repository-ul poate fi accesat și prin scanarea următorului cod QR, introducând parola din paranteză:



Scanează-mă!(etc22)

8 Referințe bibliografice

- 1] [S. Du, M. Ibrahim, M. Shehata și W. Badawy, „Shan Du; IntelliView Technol., Inc., Calgary, AB, Canada; Lakshman, M.; Shehata, M.; Badawy, Wael; Automatic License Plate Recognition (ALPR): A State-of-the-Art Review,” *IEEE Transactions on Circuits and Systems for Video Technology*, vol. 23, nr. 2, pp. 311-325, 11 March 2017.
- 2] [CCTV Information, „An Introduction to ANPR,” [Interactiv]. Available: <https://www.cctv-information.co.uk/article/an-introduction-to-anpr/>. [Accesat 4 June 2022].
- 3] [ANPR International, „History of ANPR,” [Interactiv]. Available: <http://www.anpr-international.com/history-of-anpr/>. [Accesat 4 June 2022].
- 4] [BBC, „CCTV network tracks 'getaway car',” 21 November 2005. [Interactiv]. Available: http://news.bbc.co.uk/2/hi/uk_news/england/bradford/4455918.stm. [Accesat 4 June 2022].
- 5] [Wikipedia, „automatic number-plate recognition,” 1 August 2021. [Interactiv]. Available: https://en.wikipedia.org/wiki/Automatic_number_plate_recognition. [Accesat 4 June 2022].
- 6] [H. M., „<https://www.illawarramercury.com.au/story/113726/mass-surveillance-system-nicks-drivers/>,” Illawarra Mercury, 6 June 2012. [Interactiv]. Available: <https://www.illawarramercury.com.au/story/113726/mass-surveillance-system-nicks-drivers/>. [Accesat 4 June 2022].
- 7] [Wayback machine, „web.archive.org,” [Interactiv]. Available: <https://web.archive.org/web/20080409035619/http://www.extremecctv.com/pdf/productnews/CN040422-Extreme-CCTV-Announces-Contract-for-Stockholm-Traffic-Cameras.pdf>. [Accesat 4 June 2022].
- 8] [Dutch Attorney General, „www.om.nl,” [Interactiv]. Available: https://www.om.nl/onderwerpen/verkeer/veelgestelde_vragen/trajectcontrole/. [Accesat 4 June 2022].
- 9] [„License Plate Recognition, Tribal Casinos, and banned Persons,” [Interactiv]. Available: https://www.indiangaming.com/istore/Feb11_Wanser.pdf. [Accesat 4 June 2022].
- 10] [www.thenewspaper.com, „UK Billboards Equipped with License Plate Spy Cameras,” 25 September 2009. [Interactiv]. Available: <http://www.thenewspaper.com/news/29/2907.asp>. [Accesat 4 June 2022].

- 11] [G. J., „PREPARED FOR THE CALIFORNIA AIR RESOURCES BOARD AND THE CALIFORNIA ENVIRONMENTAL PROTECTION AGENCY,” *MICROSCALE EMISSIONS MODELING SYSTEM*, pp. 96-316, 2002.
- 12] [DIGI24, „Aproape 6.000 de copii au dispărut de acasă în ultimul an. 106 nu au fost încă găsiți,” 26 May 2021. [Interactiv]. Available: <https://www.digi24.ro/stiri/actualitate/social/aproape-6-000-de-copii-au-disparut-de-acasa-in-ultimul-an-106-nu-au-fost-inca-gasiti-1541827>. [Accesat 5 June 2022].
- 13] [Ziare.com, „Statistici îngrijorătoare: În România, peste 5.000 de copii au dispărut de acasă în ultimul an,” 25 May 2019. [Interactiv]. Available: <https://ziare.com/social/romani/statistici-ingrijoratoare-in-romania-pest-5-000-de-copii-au-disparut-de-acasa-in-ultimul-an-1562918>. [Accesat 5 June 2022].
- 14] [HotNews, „Bătăie în trafic în Capitală. A fost lovit și un polițist în civil care intervenea pentru a aplana conflictul,” 1 June 2022. [Interactiv]. Available: <https://www.hotnews.ro/stiri-esential-25593099-bataie-trafic-capitala-fost-lovit-politist-civil-care-intervenea-pentru-aplana-conflictul.htm>. [Accesat 5 June 2022].
- 15] [A. Pavel și A. Popescu, „VIDEO Bătăie în trafic pe Valea Prahovei. Zece persoane s-au încăierat pe DN1, în zona Comarnic/ Printre protagoniști, o femeie cu un copil în brațe,” 3 January 2022. [Interactiv]. Available: <https://www.g4media.ro/video-bataie-in-trafic-pe-valea-prahovei-zece-persoane-s-au-incaierat-pe-dn1-in-zona-comarnic-printre-protagonisti-o-femeie-cu-un-copil-in-brate.html>. [Accesat 5 June 2022].
- 16] [O. Oanta, „VIDEO. Bătăie în traficul din București. Un curier pe bicicletă a ajuns pe capota unei mașini,” 6 January 2022. [Interactiv]. Available: <https://stirileprotv.ro/stiri/socant/bataie-in-traficul-din-bucuresti-un-curier-pe-bicicleta-a-ajuns-dus-pe-capota-unei-masini.html>. [Accesat 5 June 2022].
- 17] [G. Marina, „Un fenomen periculos ia amploare. Sute de șoferi circulă fără permis în București, iar numărul lor crește,” 16 March 2021. [Interactiv]. Available: <https://www.digi24.ro/stiri/actualitate/evenimente/un-fenomen-periculos-ia-amploare-sute-de-soferi-circula-fara-permis-in-bucuresti-iar-numarul-lor-creste-1468984>. [Accesat 5 June 2022].
- 18] [I. Sirbu, „Ultima nebunie pe șosele din România: înmulțirea cazurilor de șoferi fără permis. „Înainte era văzută ca o abatere foarte gravă, azi pare ceva semi-nevinovat,” 2 May 2022. [Interactiv]. Available: <https://www.fanatik.ro/ultima-nebunie-pe-sosele-din-romania-inmultirea-cazurilor-de-soferi-fara-permis-inainte-era-vazuta-ca-o-abatere-foarte-grava-azi-pare-ceva-semi-nevinovat-19968005>. [Accesat 5 June 2022].
- 19] [C. Laiu, „Violența domestică în România | De la teamă și rușine la speranța că va fi bine,” 26 November 2021. [Interactiv]. Available: <https://semneletimpului.ro/social/familie/violenta-domestica-in-romania-de-la-teama-si-rusine-la-speranta-ca-va-fi-bine.html>. [Accesat 5 June 2022].

- [S. Dojan, „Drama femeilor abuzate și eșecul statului român în a le proteja pe timp de pandemie,” 24 October 2021. [Interactiv]. Available: <https://romania.europalibera.org/a/drama-femei-abuz-domestic/31521522.html>. [Accesat 5 June 2022].
- [Digi24, „40% din ordinele de protecție sunt încălcate. În fiecare oră, o femeie sună la 112 pentru a-și reclama partenerul violent,” 27 April 2021. [Interactiv]. Available: <https://www.digi24.ro/stiri/actualitate/evenimente/40-din-ordinele-de-protectie-sunt-incalcate-in-fiecare-ora-o-femeie-suna-la-112-pentru-a-si-reclama-partenerii-violenti-1509845>. [Accesat 5 June 2022].
- [N. McCarthy, „Infographic: The EU's Hotspots For People Trafficking,” 2 June 2016. [Interactiv]. Available: <https://www.statista.com/chart/4947/the-eus-hotspots-for-people-trafficking/>. [Accesat 5 June 2022].
- [Asociația Națională a Evaluatorilor de Risc la Securitatea Fizică din România, „Coeficienti de criminalitate,” 2020. [Interactiv]. Available: <https://www.anersf.ro/coeficienti-de-criminalitate/>. [Accesat 5 June 2022].
- [Poliția Română, „Poliția Română,” 2021. [Interactiv]. Available: <https://politiaromana.ro/ro/auto-furate>. [Accesat 5 June 2022].
- [A. Radu, „INFOGRAFIC: Cate masini au fost furate in 2021?,” 11 March 2022. [Interactiv]. Available: <https://www.1asig.ro/INFOGRAFIC-Cate-masini-au-fost-furate-in-2021-articol-3,100-68099.htm>. [Accesat 5 June 2022].
- [A. Toma, „Peste 150 de mașini furate în străinătate au fost descoperite în 2021 la intrarea în România. Șoferii au declarat că sunt „cumpărători de bună credință,” 2 January 2022. [Interactiv]. Available: <https://ziare.com/politia-de-frontiera/masini-furate-gasite-la-frontiera-2021-1718154>. [Accesat 5 June 2022].
- [A. M. Turing, „Computing machinery and intelligence,” Aberdeen University Press, Aberdeen, 1950.
- [A. Garland, Regizor, *Ex Machina*. [Film]. United States of America: Universal Studios, 2014.
- [Z. Mahmood, K. Khan, U. Khan, S. H. Adil, S. S. A. Ali și M. Shahzad, „Towards Automatic License Plate Detection,” *Sensors*, 7 February 2022.
- [U.S. Department of Justice, National Institute of Justice, Automated License Plate Recognition Systems: Policy and Operational Guidance for Law Enforcement, Alexandria, Virginia, 2012.
- [American Civil Liberties Union, YOU ARE BEING TRACKED How License Plate Readers Are Being Used To Record Americans' Movements, 2013.
- [Plate Recognizer, „Automatic License Plate Recognition - High Accuracy ALPR,” [Interactiv]. Available: <https://platerecognizer.com/>. [Accesat 4 June 2022].

- [DevoDep, „AXIS P1445-LE-3 LPR KIT/PLATE VERIFIER KIT IN,”
33] [Interactiv]. Available: <https://devodep.ro/camere-de-supraveghere/262446-axis-p1445-le-3-lpr-kitplate-verifier-kit-in.html>. [Accesat 4 June 2022].
- [www.leonadocompany-us.com, „The Plate Hunter Mobile License Plate
34] Camera,” [Interactiv]. Available: <https://www.leonardocompany-us.com/lpr/elsag-mobile>. [Accesat 4 June 2022].
- [eBay, „Remington ELSAG ALPR License Plate Reader MPH-900 Mobile
35] Plate Hunter Scanner,” [Interactiv]. Available: <https://www.ebay.com/itm/265115650893>. [Accesat 4 June 2022].
- [T. M. Mitchell, „Machine Learning,” McGraw Hill, New York, 1997.
36]
- [J. Brownlee, „Transfer Learning in Keras with Computer Vision Models,”
37] Machine Learning Mastery, 14 March 2019. [Interactiv]. Available: <https://machinelearningmastery.com/how-to-use-transfer-learning-when-developing-convolutional-neural-network-models/>. [Accesat 4 June 2022].
- [Analytics Vidhya, „Computer Vision to Detect License Number Plate,” 30
38] December 2021. [Interactiv]. Available: <https://www.analyticsvidhya.com/blog/2021/12/computer-vision-to-detect-license-number-plate/>. [Accesat 4 June 2022].
- [www.learnopencv.com, „Automatic License Plate Recognition using
39] Deep Learning,” 15 March 2022. [Interactiv]. Available: https://learnopencv.com/automatic-license-plate-recognition-using-deep-learning/?ck_subscriber_id=452195442. [Accesat 4 June 2022].
- [A. Chaudhuri, K. Mandaviya, P. Badelia și S. K. Ghosh, „Optical
40] Character Recognition System for Different Languages with Soft Computing,” *Studies in Fuziness and Soft Computing*, pp. 1-108.
- [AI & Machine Learning Blog, „[Tutorial] OCR in Python with Tesseract,
41] OpenCV and Pytesseract,” 5 December 2019. [Interactiv]. Available: <https://nanonets.com/blog/ocr-with-tesseract/>. [Accesat 4 June 2022].
- [Simplilearn.com, „Top Python Machine Learning Libraries,” 25 November
42] 2020. [Interactiv]. Available: <https://www.simplilearn.com/python-machine-learning-libraries-article>. [Accesat 4 June 2022].
- [TensorFlow, „TensorFlow,” 2019. [Interactiv]. Available:
43] <https://www.tensorflow.org/>. [Accesat 4 June 2022].
- [R. Vickery, „The Python Machine Learning Ecosystem,” 11 April 2022.
44] [Interactiv]. Available: <https://towardsdatascience.com/the-python-machine-learning-ecosystem-7c05be4ac48d>. [Accesat 4 June 2022].
- [P. D. R. G. K. H. B. H. S. B. T.-Y. Lin, „Feature pyramid networks for
45] object detection,” *Proceedings of the IEEE conference on computer vision and pattern*, pp. 2117-2125, 2017.

- [B. Y. P. F. P. A. K. N. T. D. Minaee S, „Image Segmentation Using Deep Learning: A Survey,” *IEEE Trans Pattern Anal Mach Intell*.
46]
- [Praveen, „License Plate Recognition using OpenCV Python,” Medium, 9
47] July 2020. [Interactiv]. Available: <https://medium.com/programming-fever/license-plate-recognition-using-opencv-python-7611f85cdd6c>. [Accesat 4 June 2022].
- [A. Rosebrock, „Intersection over Union (IoU) for object detection,” 7
48] November 2016. [Interactiv]. Available: <https://pyimagesearch.com/2016/11/07/intersection-over-union-iou-for-object-detection/>. [Accesat 12 June 2022].
- [J. Hui, „mAP (mean Average Precision) for Object Detection,” 7 March
49] 2018. [Interactiv]. Available: <https://jonathan-hui.medium.com/map-mean-average-precision-for-object-detection-45c121a31173>. [Accesat 12 June 2022].
- [www.javatpoint.com, „Number Plate Recognition using Python -
50] Javatpoint,” [Interactiv]. Available: <https://www.javatpoint.com/number-plate-recognition-using-python>. [Accesat 4 June 2022].
- [PyImageSearch, „OpenCV: Automatic License/Number Plate
51] Recognition (ANPR) with Python,” 21 September 2020. [Interactiv]. Available: <https://pyimagesearch.com/2020/09/21/opencv-automatic-license-number-plate-recognition-anpr-with-python/>. [Accesat 4 June 2022].
- [Openalpr.com, „OpenALPR - Automatic License Plate Recognition,”
52] 2020. [Interactiv]. Available: <https://www.openalpr.com/>. [Accesat 4 June 2022].
- [[Interactiv]. Available: <https://www.statista.com/chart/4947/the-eus-hotspots-for-people-trafficking/>.
53]

DECLARAȚIE DE AUTENTICITATE ALUCRĂRII DE FINALIZARE A STUDIILOR *

Subsemnatul

_____, legitimat cu _____ seria _____ nr. _____
_____, CNP _____

autorul lucrării

_____ elaborată în vederea susținerii examenului de finalizare a studiilor de _____
_____ organizat de către Facultatea _____
_____ din cadrul
Universității Politehnica Timișoara, sesiunea _____ a anului
universitar _____, coordonator _____,
luând în considerare conținutul art. 34 din Regulamentul privind organizarea și
desfășurarea examenelor de licență/diplomă și disertație, aprobat prin HS nr.
109/14.05.2020 și cunoscând faptul că în cazul constatării ulterioare a unor declarații
false, voi suporta sancțiunea administrativă prevăzută de art. 146 din Legea nr. 1/2011
– legea educației naționale și anume anularea diplomei de studii, declar pe proprie
răspundere, că:

- această lucrare este rezultatul propriei activități intelectuale,
- lucrarea nu conține texte, date sau elemente de grafică din alte lucrări sau din alte surse fără ca acestea să nu fie citate, inclusiv situația în care sursa o reprezintă o altă lucrare/alte lucrări ale subsemnatului.
- sursele bibliografice au fost folosite cu respectarea legislației române și a convențiilor internaționale privind drepturile de autor.
- această lucrare nu a mai fost prezentată în fața unei alte comisii de examen de licență/diplomă/disertație.

Timișoara,

Data

Semnătura

* Declarația se completează „de mână” și se inserează în lucrarea de finalizare a studiilor, la sfârșitul acesteia, ca parte integrantă